


# Predicción de Cancer de Mama con Imágenes Histológicas usando Deep Learning

## Resumen

El modelo EfficientNetB0 alcanzó un AUC de 0.96 y un Recall superior a 0.93, logrando identificar correctamente más del 93% de los casos positivos. La precisión fue de aproximadamente 0.71, reflejando algunos falsos positivos, aceptables en el contexto clínico. La exactitud global superó el 87% y la pérdida final fue de 0.29, mostrando un entrenamiento estable. En comparación, la CNN personalizada presentó mayor cantidad de falsos negativos. EfficientNetB0 ofreció un mejor equilibrio entre sensibilidad y especificidad, confirmando su mayor aplicabilidad clínica. La interfaz desarrollada en Gradio permitió visualizar predicciones con la probabilidad asociada, facilitando la interpretación.

## Introducción

El carcinoma ductal invasivo es uno de los subtipos más frecuentes y agresivos de cáncer de mama. La histopatología digital constituye el estándar diagnóstico, pero su lectura manual es lenta y dependiente del observador. Los avances en Deep Learning han permitido automatizar la clasificación de imágenes médicas, mejorando la precisión y reduciendo la variabilidad. Este estudio plantea el uso de EfficientNetB0 para apoyar el diagnóstico temprano y reducir la omisión de casos positivos.



Tipo de Imágenes utilizadas

## Objetivos


Desarrollar un sistema de clasificación de imágenes histológicas de mama utilizando EfficientNetB0 con Transfer Learning para la detección de carcinoma ductal invasivo, priorizando la reducción de falsos negativos y facilitando su implementación mediante una interfaz accesible para usuarios clínicos.

## Materiales y métodos

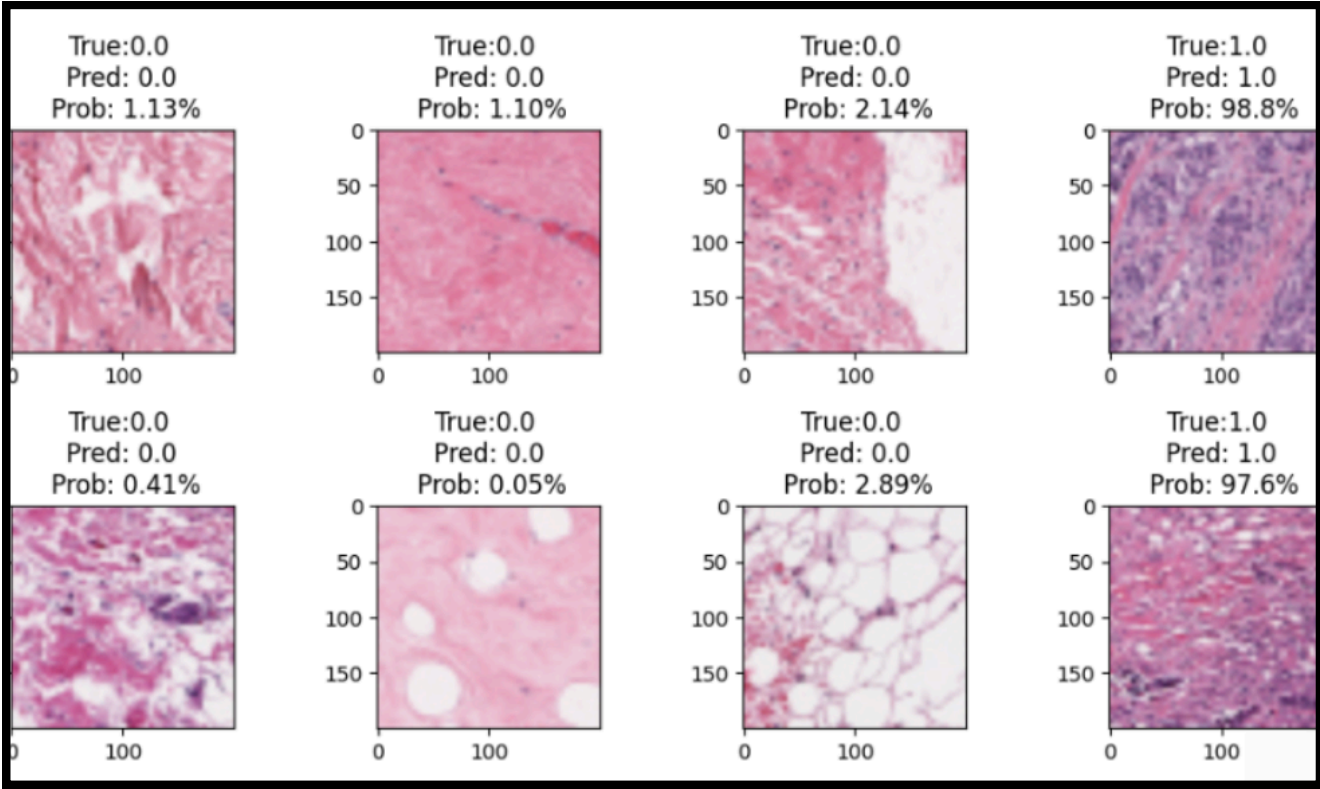
Se utilizó el conjunto Breast Histopathology Images, compuesto por 277,524 parches de 50×50 píxeles teñidos con H&E, con un desbalance de 71.6% benignos y 28.4% malignos. Las imágenes fueron redimensionadas a 200×200 píxeles, normalizadas en rango [0,1] y balanceadas mediante SMOTE aplicado a nivel de embeddings. Para aumentar la robustez se aplicaron rotaciones, volteos, traslaciones y ajustes de brillo y contraste. Se comparó una CNN personalizada frente a EfficientNetB0 con Transfer Learning de ImageNet. El entrenamiento utilizó el optimizador Adam, binary crossentropy, 15 épocas, batch size de 8 y callbacks de EarlyStopping y ModelCheckpoint. Finalmente, se desarrolló una interfaz interactiva con Gradio para realizar pruebas en tiempo real.

## Resultados

El cáncer de mama es una de las principales causas de mortalidad en mujeres. Este trabajo presenta un clasificador binario para la detección de carcinoma ductal invasivo (IDC) a partir del conjunto Breast Histopathology Images, empleando la arquitectura EfficientNetB0 con Transfer Learning. El flujo de trabajo incluyó normalización, redimensionamiento de imágenes y aumentos de datos específicos, además de un balanceo inicial con SMOTE. El modelo alcanzó un AUC de 0.9558 y un Recall de 0.9319, priorizando la reducción de falsos negativos, aspecto crítico en aplicaciones clínicas. Asimismo, se desarrolló una interfaz en Gradio que permite predicciones en tiempo real, acercando esta tecnología a usuarios no técnicos.



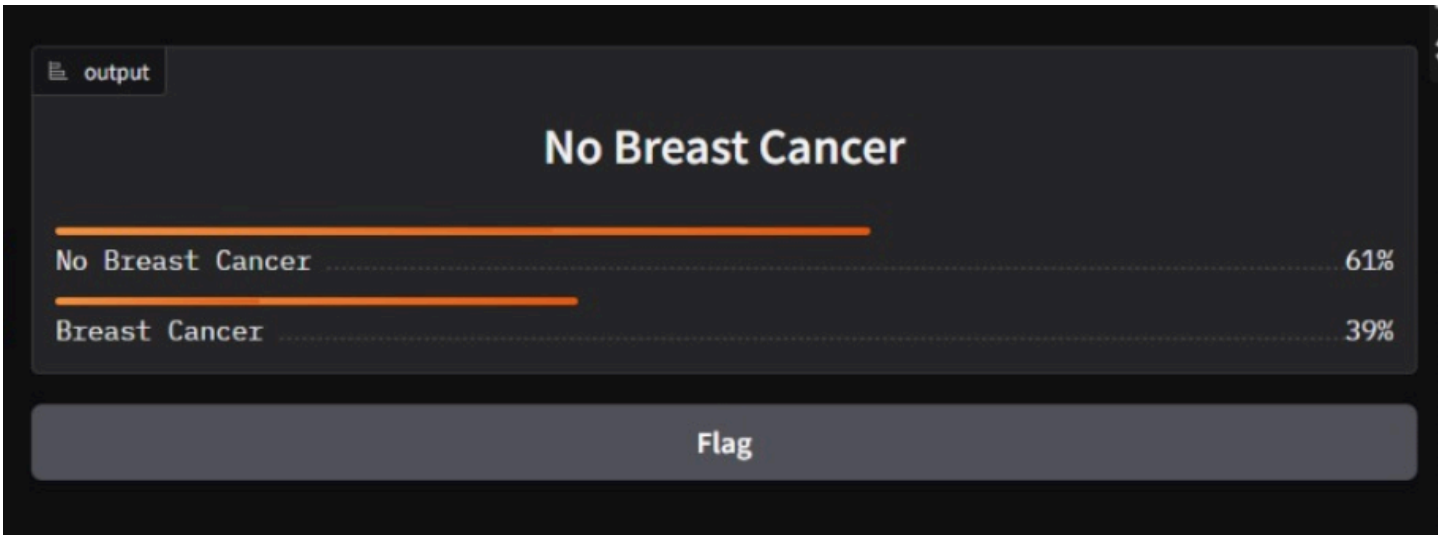
Comparativa entre modelos



Ejemplo de salida visual del modelo en la clasificación de imágenes IDC-- e IDC+.



Interfaz de gradio - insertar imagen



Interfaz de gradio - diagnóstico

## Conclusiones

El uso de EfficientNetB0 con Transfer Learning demostró un alto rendimiento en la clasificación histológica de cáncer de mama, reduciendo falsos negativos y aportando confianza al diagnóstico temprano. La incorporación de una interfaz en Gradio facilita su adopción por parte de personal clínico sin conocimientos técnicos. Como trabajo futuro se propone el uso de modelos generativos (GANs y diffusion models) para mejorar el balance de clases y la integración del sistema en flujos clínicos estandarizados compatibles con DICOM/DICOMweb.

## Referencias

- Tan, M. & Le, Q. EfficientNet: ICML, 2019.
- Mooney, P. Breast Histopathology Images (IDC). Kaggle, 2018.
- Litjens, G. et al. Medical Image Analysis, 2017.
- Campanella, G. et al. JAMA Oncology, 2019.
- Kim, H. E. et al. BMC Medical Imaging, 2022.